

神经网络与大语言模型的拓扑斯理论框架

2026 年 6 月 26 日

摘要

本文综述一条近期出现的研究方向：其共同目标并不是证明拓扑斯理论已经成为人工智能中的成熟工程范式，而是说明某些神经网络和大语言模型结构可以被表示、补全或语义化地组织在范畴论和拓扑斯理论框架中。本文首先给出统一的理论预备知识，从范畴、函子、自然变换、极限、伴随、预层、Yoneda 引理、层、site、Grothendieck 拓扑、Grothendieck 拓扑斯、内部逻辑和 stack 讲起，并尽量说明这些概念在后续 AI 相关工作中扮演的角色。随后讨论若干代表性工作：Lafforgue 关于 Grothendieck 拓扑斯与 AI 的纲领性想法，Belfiore 和 Bennequin 关于深度神经网络的拓扑斯与 stack 框架，已经在 arXiv 上撤回但具有启发性的 transformer 拓扑斯工作，Mahadevan 关于生成式 AI 和 LLM 的拓扑斯理论提案，以及 Jia、Peng、Yang、Chen 的 2025 年综述。本文重点区分哪些部分是稳定的拓扑斯理论，哪些是结构性表示框架，哪些只是研究纲领或探索性想法。

1 引言

现代神经网络通常被写成一个带参数的映射：

$$N_\theta : X \longrightarrow Y,$$

或者写成若干层的复合：

$$N_\theta = f_L \circ f_{L-1} \circ \cdots \circ f_1.$$

这种写法对优化、实现和实验评估非常有效，但它并不能充分回答以下结构性问题：

1. 局部表示、层结构、模块、对称性、不变量和语义如何组织成全局结构？
2. 神经网络能否被看成某个足够丰富的范畴中的对象？
3. Transformer 或 LLM 的表达能力能否通过范畴补全、函数对象、子对象或内部逻辑描述？
4. 模型组合能否由 pullback、pushout、equalizer、coequalizer、exponential object 等泛构造支配？

拓扑斯理论之所以出现在这些问题中，是因为 Grothendieck 拓扑斯可以粗略理解为某个 site 上的层范畴：

$$\mathcal{E} \simeq \mathbf{Sh}(\mathcal{C}, J).$$

这里 $\mathcal{C}$ 是一个上下文范畴， J 是 Grothendieck 拓扑，用来规定哪些族应该被看作覆盖， $\mathbf{Sh}(\mathcal{C}, J)$ 是满足局部-全局粘合条件的层组成的范畴。这样的范畴同时像广义空间、广义集合宇宙和带有内部逻辑的语义宇宙。

需要强调的是，本文讨论的工作成熟度并不相同。有些给出了明确的范畴构造；有些是研究纲领；有些是探索性提案；其中关于 transformer 拓扑斯的一篇文章已经在 arXiv 上标注为 withdrawn。因此，本文不会把这些工作说成已经证明了“AI 为什么有效”，而是把它们理解为一系列把神经结构放入更丰富语义环境的数学尝试。

2 统一符号

全文使用如下符号。

符号	含义
$\mathcal{C}, \mathcal{D}$	范畴，构造预层时通常假定为小范畴
A, B, C, U, V	范畴中的对象
$f : A \rightarrow B$	态射
$\mathbf{Set}$	集合与函数组成的范畴
$\mathbf{PSh}(\mathcal{C})$	预层范畴 $[\mathcal{C}^{op}, \mathbf{Set}]$
F, G	函子或预层
$\eta : F \Rightarrow G$	自然变换
$y : \mathcal{C} \rightarrow \widehat{\mathcal{C}}$	Yoneda 嵌入
yA	可表预层 $\mathrm{Hom}_{\mathcal{C}}(-, A)$
J	$\mathcal{C}$ 上的 Grothendieck 拓扑
$(\mathcal{C}, J)$	site，即带覆盖结构的范畴
$\mathbf{Sh}(\mathcal{C}, J)$	site 上的层范畴
$\mathcal{E}, \mathcal{F}$	拓扑斯
Ω	子对象分类器
N_{θ}	参数为 θ 的神经网络
h_{ℓ}	第 ℓ 层的隐藏表示
T_{θ}	transformer 或 LLM 型模型

对于神经网络，我们使用轻量符号。一个前馈网络写作：

$$h_{\ell+1} = f_{\ell, \theta_\ell}(h_\ell), \quad N_\theta = f_{L, \theta_L} \circ \cdots \circ f_{1, \theta_1}.$$

Transformer block 可以示意性写成:

$$H_{\ell+1} = \text{FFN}_\ell(\text{Attn}_\ell(H_\ell)),$$

其中 H_ℓ 是第 ℓ 层的 token 隐藏状态序列。本文不关心具体训练细节，而关心这些层、head、状态、参数、对称性和任务如何被组织为范畴对象与态射。

3 范畴论预备知识

3.1 范畴、函子与自然变换

一个范畴 $\mathcal{C}$ 由对象、态射、恒等态射和满足结合律的复合构成。两个对象 $A, B \in \mathcal{C}$ 之间的态射集合记为:

$$\text{Hom}_{\mathcal{C}}(A, B).$$

一个函子

$$F : \mathcal{C} \rightarrow \mathcal{D}$$

把对象送到对象，把态射送到态射，并保持恒等与复合:

$$F(\text{id}_A) = \text{id}_{F(A)}, \quad F(g \circ f) = F(g) \circ F(f).$$

两个函子 $F, G : \mathcal{C} \rightarrow \mathcal{D}$ 之间的自然变换

$$\eta : F \Rightarrow G$$

给每个对象 $A \in \mathcal{C}$ 一个态射

$$\eta_A : F(A) \rightarrow G(A),$$

并要求对每个 $f : A \rightarrow B$ 有自然性条件:

$$G(f) \circ \eta_A = \eta_B \circ F(f).$$

在 AI 相关的拓扑斯工作中，函子常用来表达结构化翻译，例如从几何对象到语义对象，从网络组件到范畴对象，从句法描述到语义模型。自然变换则表达这些翻译之间的相容性。

3.2 极限与泛性质

极限是用泛性质定义对象的系统方法。最重要的有限极限包括终对象、积、等化子和拉回。

给定两个态射：

$$A \xrightarrow{f} C \xleftarrow{g} B,$$

它们的拉回是一个对象 $A \times_C B$ ，带有投影

$$p_1 : A \times_C B \rightarrow A, \quad p_2 : A \times_C B \rightarrow B,$$

满足

$$f \circ p_1 = g \circ p_2,$$

并且对所有满足同样相容条件的对象具有泛性质。在 **Set** 中，

$$A \times_C B = \{(a, b) \in A \times B \mid f(a) = g(b)\}.$$

在 AI 中，拉回可以理解为“在共同语义空间上对齐”。如果图像表示 I 和文本表示 T 都映到语义空间 S ：

$$I \rightarrow S, \quad T \rightarrow S,$$

那么 $I \times_S T$ 表示语义一致的图文配对。这个例子本身还不是拓扑斯理论，但它展示了泛构造如何表达模型结构。

3.3 伴随

设

$$L : \mathcal{C} \rightarrow \mathcal{D}, \quad R : \mathcal{D} \rightarrow \mathcal{C}.$$

如果有自然双射

$$\mathrm{Hom}_{\mathcal{D}}(LC, D) \cong \mathrm{Hom}_{\mathcal{C}}(C, RD),$$

则称 L 左伴随于 R ，记作：

$$L \dashv R.$$

左伴随通常对应自由构造或补全，右伴随通常对应遗忘结构或限制结构。例如自由群函子和遗忘函子满足：

$$F : \mathbf{Set} \rightarrow \mathbf{Grp} \dashv U : \mathbf{Grp} \rightarrow \mathbf{Set}.$$

伴随在拓扑斯理论中无处不在。层化是层范畴嵌入预层范畴的左伴随；几何态射是一对伴随函子；内部逻辑中的存在量词和全称量词也可以通过伴随来表达。

3.4 预层与 Yoneda 引理

给定范畴 $\mathcal{C}$ ，一个预层是反变函子：

$$F : \mathcal{C}^{op} \rightarrow \mathbf{Set}.$$

所有预层组成的范畴记为：

$$\widehat{\mathcal{C}} = \mathbf{PSh}(\mathcal{C}) = [\mathcal{C}^{op}, \mathbf{Set}].$$

对每个对象 $A \in \mathcal{C}$ ，有一个可表预层：

$$yA = \mathrm{Hom}_{\mathcal{C}}(-, A).$$

Yoneda 引理说，对任意预层 F ，有自然同构：

$$\mathrm{Nat}(yA, F) \cong F(A).$$

这表示 $F(A)$ 中的一个元素，等价于一个从所有广义元素 $X \rightarrow A$ 自然地产生 F -数据的规则。
Yoneda 嵌入

$$y : \mathcal{C} \rightarrow \widehat{\mathcal{C}}$$

是 full and faithful，即

$$\mathrm{Hom}_{\mathcal{C}}(A, B) \cong \mathrm{Nat}(yA, yB).$$

因此预层范畴可以看作原范畴的自然补全：它完整包含原范畴，同时加入了更一般的上下文依赖对象。

3.5 Site、层与层化

Grothendieck 拓扑 J 给范畴 $\mathcal{C}$ 中每个对象 U 指定哪些族

$$\{U_i \rightarrow U\}_{i \in I}$$

应当被看作覆盖。带有这种覆盖结构的范畴 $(\mathcal{C}, J)$ 称为 site。

一个预层 $F : \mathcal{C}^{op} \rightarrow \mathbf{Set}$ 是层，如果对每个覆盖族，兼容的局部截面可以唯一粘成全局截面。在拓扑空间的经典情形中，若

$$U = \bigcup_i U_i$$

且 $s_i \in F(U_i)$ 满足

$$s_i|_{U_i \cap U_j} = s_j|_{U_i \cap U_j},$$

则存在唯一 $s \in F(U)$ ，使得

$$s|_{U_i} = s_i.$$

层化把预层 F 修正为层 aF 。设

$$i : \mathbf{Sh}(\mathcal{C}, J) \hookrightarrow \mathbf{PSh}(\mathcal{C})$$

是包含函子，则层化满足伴随：

$$a \dashv i.$$

直观上，层化修补两类缺陷：

1. 局部相同应该推出全局相同；
2. 兼容局部数据应该能粘成全局数据。

这正是层与神经网络相关的原因：它形式化了从局部描述到全局一致描述的过程。

3.6 Grothendieck 拓扑斯

Grothendieck 拓扑斯是等价于某个 site 上层范畴的范畴：

$$\mathcal{E} \simeq \mathbf{Sh}(\mathcal{C}, J).$$

它有三种互补直觉：

1. 广义空间；
2. 随上下文变化的广义集合宇宙；
3. 具有内部逻辑的语义宇宙。

典型例子包括：

$$\mathbf{Set} \simeq \mathbf{Sh}(*),$$

拓扑空间 X 上的层范畴 $\mathbf{Sh}(X)$ ，以及任意小范畴上的预层范畴：

$$[C^{op}, \mathbf{Set}].$$

在 AI 相关工作中，Grothendieck 拓扑斯往往被用作语义环境：局部结构、不变量、数据和逻辑断言都可以在其中组织起来。

3.7 子对象分类器与内部逻辑

一个 elementary topos 有有限极限、指数对象和子对象分类器 Ω 。子对象分类器推广了集合论中的二值真值集合。在 $\mathbf{Set}$ 中，子集 $S \subseteq X$ 由特征函数分类：

$$\chi_S : X \rightarrow \{0, 1\}.$$

在拓扑斯 $\mathcal{E}$ 中，子对象 $S \hookrightarrow X$ 由态射

$$\chi_S : X \rightarrow \Omega$$

分类。

因此，谓词对应子对象，真值存在于对象 Ω 中。拓扑斯于是支持内部逻辑。对于 AI，这意味着语义断言、概念成员关系、解释性条件或上下文真值可以在一个范畴内部表达，而不必仅仅作为外部布尔标签。

3.8 Stack

层粘合集合值局部数据。Stack 粘合范畴值局部数据，不仅粘合对象，还粘合对象之间的态射或同构。粗略地说：

层：局部对象可以粘合， stack：局部对象及其等价也可以粘合。

在深度神经网络相关文献中，当局部表示不应严格相等，而只应在某种坐标变换、对称性、规范变换或同构意义下相等时，stack 语言就会出现。这对于层、head、特征空间之间的等价描述尤其自然。

4 AI 算法背景的最小介绍

本文只需要非常少的 AI 算法背景。一个前馈 DNN 是带参数映射的复合：

$$N_{\theta} = f_{L, \theta_L} \circ \cdots \circ f_{1, \theta_1}.$$

CNN 加入局部卷积和近似的平移等变结构；RNN 或 LSTM 加入序列状态；Transformer 使用 attention 机制计算上下文化的 token 表示；大语言模型则是大规模训练的 transformer，用于建模 token 分布。

本文讨论的拓扑斯工作通常不依赖具体训练细节。它们抽象的是神经架构中的组件、映射、状态、参数、对称性和语义关系。

5 Lafforgue: Grothendieck 拓扑斯作为 AI 语义补全

Laurent Lafforgue 的 2022 年讲稿 *Some Possible Roles for AI of Grothendieck Topos Theory* 是纲领性文本。其核心动机是：神经网络处理大量数值函数，但数学意义往往来自这些数值背后的几何或逻辑结构。Grothendieck 拓扑斯可能用于保留并丰富这种有意义的来源。

用范畴语言说，可以从一个有意义对象的范畴 $\mathcal{C}$ 出发，例如几何形状、符号结构或知识对象。通过 Yoneda 嵌入：

$$y : \mathcal{C} \rightarrow \widehat{\mathcal{C}},$$

原范畴进入一个预层宇宙。再给 $\mathcal{C}$ 加上 Grothendieck 拓扑 J ，并取层范畴：

$$\mathbf{Sh}(\mathcal{C}, J),$$

就得到一个更丰富的范畴，在其中可以处理局部-全局结构、广义函数和语义不变量。

这篇讲稿的结论不是一个已经实现的学习算法，而是一个研究纲领：

有意义的范畴 $\rightarrow$ 预层补全 $\rightarrow$ 层/拓扑斯补全.

它实际用到的预备知识包括 Yoneda 嵌入、层化、site、Grothendieck 拓扑和 Grothendieck 拓扑斯。这里的拓扑斯不是梯度学习的替代品，而是语义补全机制。

6 Belfiore 和 Bennequin: 深度神经网络的拓扑斯与 Stack

Jean-Claude Belfiore 和 Daniel Bennequin 的 *Topos and Stacks of Deep Neural Networks* 是把 DNN 与 Grothendieck 拓扑斯、stack 直接联系起来的最雄心勃勃的工作之一。

其核心主张可以概括为：

已知深度神经网络可以表示为 canonical Grothendieck topoi 中的对象，其不变性结构可以由 stacks 描述。

这个观点认为 DNN 不只是一个函数

$$N_{\theta} : X \rightarrow Y,$$

而是一个包含层、状态、参数、变换、对称性和学习动态的结构化对象。这些结构可以组织成范畴和 site。相应的 Grothendieck 拓扑斯提供网络的全局语义环境，stack 则编码不变性和等价结构。

几个预备概念在这里直接出现：

- 预层与层。层级或局部网络数据可以看成赋给上下文的数据，并带有限制与粘合。
- Grothendieck 拓扑斯。网络被放入一个层论宇宙。
- 内部逻辑。关于网络行为的语义断言可以在拓扑斯内部解释。
- Stack。CNN、LSTM 等结构中的不变量和等价往往不是严格相等，而是同构意义下的粘合。

这篇工作应被理解为结构编码框架。它本身并不证明 DNN 一定泛化，也没有给出标准训练算法。它提出的是一种比“函数复合”更丰富的 DNN 范畴语义。

7 Transformer 的拓扑斯：已撤回但有启发的提案

Villani 和 McBurney 的 *The Topos of Transformer Networks* 试图把 transformer 表达能力与拓扑斯补全联系起来。arXiv 页面已将该文标记为 withdrawn，并注明 requires major revision，因此其结论必须谨慎对待。

该文的大致主张是：许多传统神经网络架构可以嵌入某种 piecewise-linear functions 的 pretopos-like 范畴，而 transformer 因其 attention 和上下文依赖结构，需要更丰富的 topos completion。

相关预备概念包括：

- **Pretopos**。具有有限极限、有限不交余积和某种有效商结构的范畴。
- **Topos completion**。把较弱的范畴环境嵌入或补全为更丰富的拓扑斯环境。
- **指数对象与内部逻辑**。Transformer 被解释为需要更丰富的函数对象和高阶表达能力。

由于该文已撤回，负责的说法不是“transformer 已经被拓扑斯定理刻画”，而是：

attention 型上下文计算是否需要超越普通一阶神经网络语义的范畴结构？

这是一个有启发性的研究问题，而不是稳定结论。

8 Mahadevan: 生成式 AI 与 LLM 的拓扑斯理论

Mahadevan 的 *Topos Theory for Generative AI and LLMs* 提出，LLM-like 系统组成的范畴可能具有拓扑斯结构，并且泛构造可以指导组合式 AI 架构设计。

其主张大致是：

1. 把 LLM 或生成模型视为某个范畴中的对象或态射；
2. 证明该范畴具有极限、余极限、指数对象和类似子对象分类器的结构；
3. 用泛构造设计或分析模型组合。

例如：

- pullback 表示语义对齐；
- pushout 表示模块融合；
- equalizer 表示模型输出的一致部分；
- coequalizer 表示按行为等价取商；
- exponential object 表示条件化或高阶模型空间；
- subobject classifier 表示关于模型行为的谓词或分类器。

因此，这篇工作几乎动用了前文所有主要预备知识：极限、余极限、指数对象、子对象、真值对象和范畴宇宙。需要注意的是，“LLM 形成一个拓扑斯”这一说法强烈依赖于对象和态射如何精确定义。如果没有精确定义模型范畴及其态射，这句话更像研究口号，而不是严格定理。

9 Jia-Peng-Yang-Chen 综述

Jia、Peng、Yang、Chen 的 *Category-Theoretical and Topos-Theoretical Frameworks in Machine Learning* 把范畴论机器学习大致分成几条路线：

- 1. 基于梯度的学习;
- 2. 基于概率的学习;
- 3. 基于不变性和等价性的学习;
- 4. 基于拓扑斯的学习。

前三类更接近已经较成熟的应用范畴论，例如 Cartesian differential categories、lenses、Markov categories、categorical probability 和 equivariant learning。第四类收集的是更探索性的 Grothendieck 拓扑斯、stack、层和内部逻辑相关工作。

这篇综述的价值是地图，而不是单一新定理。它帮助我们判断哪些范畴论机器学习较成熟，哪些仍是拓扑斯导向的探索性框架。

10 工作之间的比较

工作	主要构造或主张	使用的拓扑斯概念	状态
Lafforgue	Grothendieck 拓扑斯作为有意义 AI 对象的语义补全	Yoneda、层、site、拓扑斯	研究纲领
Belfiore-Bennequin	DNN 作为 canonical Grothendieck topoi 中的对象，不变性由 stacks 描述	Grothendieck 拓扑斯、stack、内部逻辑	雄心很大的结构框架
Transformer topos	transformer 需要超越 pretopos-like neural categories 的 topos completion	pretopos、topos completion、指数对象	已撤回，作为研究线索
Mahadevan	LLM 范畴可能形成拓扑斯，泛构造指导 AI 组合	极限、余极限、指数对象、子对象分类器	探索性提案
Jia-Peng-Yang-Chen	范畴论与拓扑斯机器学习综述	广泛综述	文献地图

共同主题不是实证定理，而是结构性主张：

神经系统应被放入能编码上下文、局部性、语义、不变性和内部逻辑的范畴中研究。

11 这些工作到底证明了什么？

我们可以把相关主张分成四个层次。

11.1 第一层：稳定的拓扑斯理论

关于预层、层、层化、Grothendieck 拓扑斯、内部逻辑和几何态射的定义与定理属于经典数学。这些是可靠的。

11.2 第二层：结构表示主张

有些工作声称某类神经架构可以表示在拓扑斯或 stack 框架中。这是数学建模主张。其价值取决于这种表示是否保留了真正重要的网络结构，而不是平凡编码。

11.3 第三层：语义解释主张

关于意义、解释性、上下文真值和内部逻辑的说法很有启发性，但需要精确定义谓词、上下文、覆盖和语义对象。

11.4 第四层：算法或实证主张

目前很少有这些直接拓扑斯工作给出类似标准 ML 论文中的性能提升、泛化界或成熟算法。这部分仍大多是开放问题。

12 研究展望

较有希望的近期方向包括：

1. 模型输出的层论一致性。用局部-全局结构衡量局部解释或预测能否粘合。
2. 模块化模型组合的范畴语义。用 pullback、pushout、equalizer、coequalizer 定义原则化组合。
3. 拓扑斯启发的知识表示。把上下文真值和证据解释为内部逻辑，而非外部布尔标签。
4. 表示不变性的 stack 语言。用 stack 或 groupoid 描述学习表示之间的等价。
5. 精确的 LLM 范畴。只有对象和态射定义足够清楚，关于极限、指数对象和子对象分类器的说法才可能成为真正定理。

13 结论

神经网络和 LLM 的拓扑斯理论应被理解为一个正在发展的语义和结构研究纲领。其核心观点是：神经网络不只是数值函数，而是包含局部数据、上下文依赖、不变量和逻辑内容的结构化对象。Grothendieck 拓扑斯、层、stack 和内部逻辑提供了组织这些特征的语言。

负责任的读法是双重的：范畴论和拓扑斯理论本身是稳定而强大的；它们在 AI 中的直接应用则仍处于不均衡的探索阶段。目前最成熟的邻近方向是 sheaf 和 topological deep learning。直接

把 DNN、transformer 和 LLM 放入拓扑斯的工作仍然偏理论和探索，但它们提出了一个清晰的数学愿景：从黑箱参数映射走向结构化语义宇宙，在其中局部计算、全局意义和上下文真值可以被统一研究。

14 参考文献

- Jean-Claude Belfiore and Daniel Bennequin, [Topos and Stacks of Deep Neural Networks](#).
- Laurent Lafforgue, [Some Possible Roles for AI of Grothendieck Topos Theory](#).
- Mattia Jacopo Villani and Peter McBurney, [The Topos of Transformer Networks](#). 该 arXiv 页面标注为 withdrawn and requiring major revision。
- Sridhar Mahadevan, [Topos Theory for Generative AI and LLMs](#).
- Yiyang Jia, Guohong Peng, Zheng Yang, and Tianhao Chen, [Category-Theoretical and Topos-Theoretical Frameworks in Machine Learning: A Survey](#); published version: [Axioms](#) 2025, 14, 204.
- Saunders Mac Lane and Ieke Moerdijk, *Sheaves in Geometry and Logic*.
- Peter Johnstone, *Sketches of an Elephant: A Topos Theory Compendium*.
- Steve Awodey, *Category Theory*.